Anomaly detection

2023年6月2日 16:23

1.原理

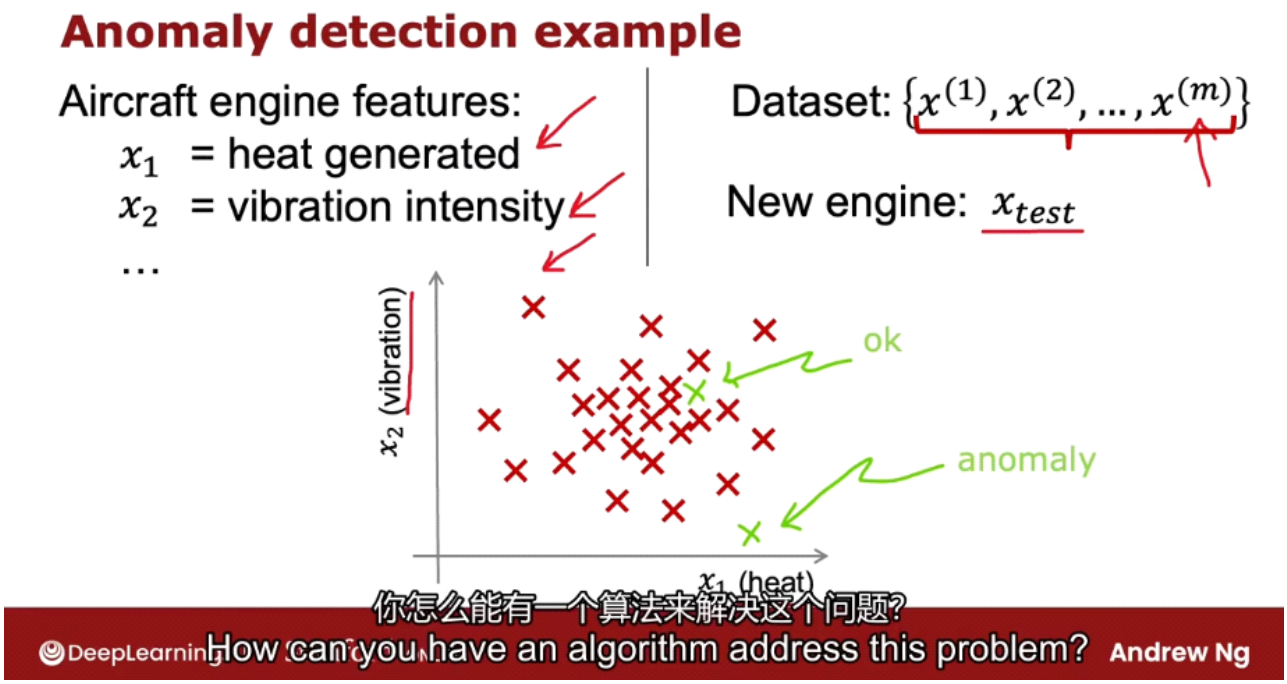

屏幕剪辑的捕获时间: 2023/6/4 21:28

密度估计(Density Estimation)

评估数据各个特征取特定值的概率，设定阈值以评估test data是否异常

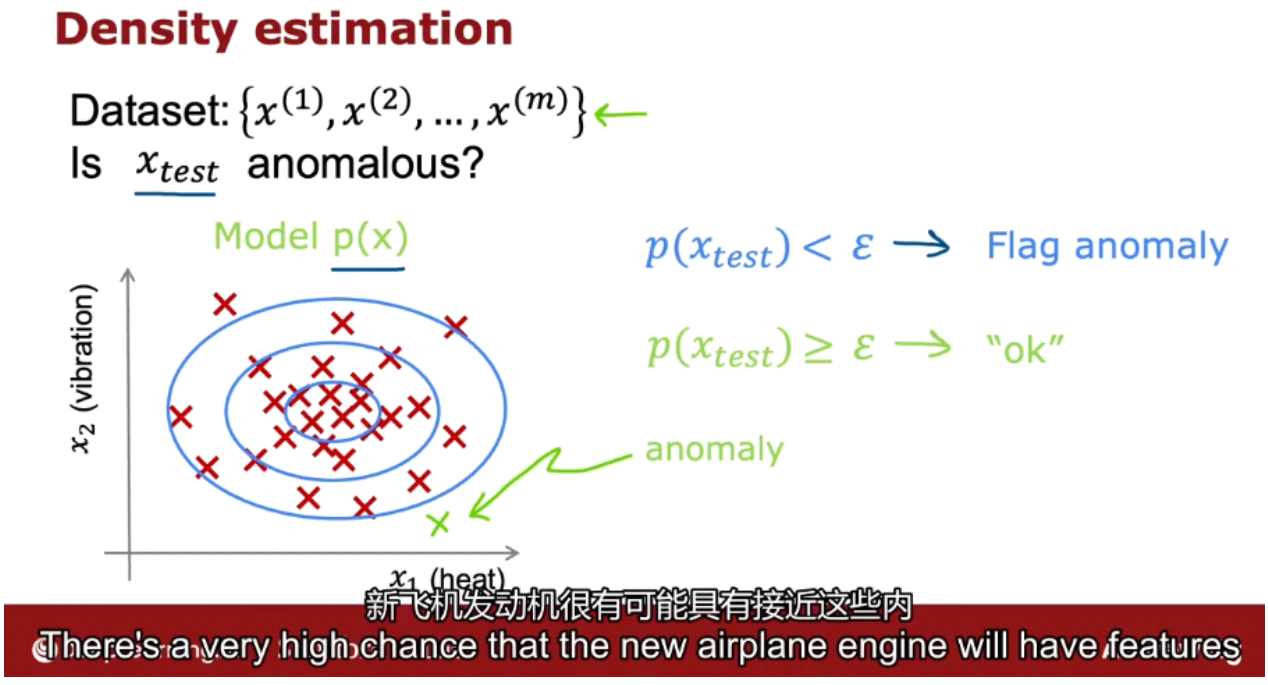

屏幕剪辑的捕获时间: 2023/6/4 21:32

异常监测在各个领域都有很多应用，主要作用是对于有轻微异常嫌疑的案例，可以指导安全团队对其进行进一步监测

2.高斯分布（正态分布）

如何应用于Anomaly Detection?

①.单个数据情况下，利用Training set拟合出正态分布，利用”3σ“原则即可；

②.对于n个特征，假设各个特征相互独立，拟合出n个正态分布模型，计算概率

Density estimation

Training set: $\{x^{(1)}, x^{(2)}, \ldots, x^{(m)}\}$

Each example x_i has n features

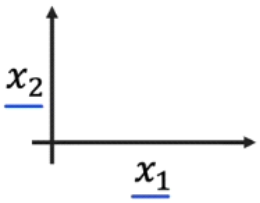

$$x = \begin{bmatrix} x_1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$p(x) = p(x_1; \mu_1, \sigma_1^2) * p(x_2; \mu_2, \sigma_2^2) * p(x_3; \mu_3, \sigma_3^2) * \ldots * p(x_n; \mu_n, \sigma_n^2)$$

$$= \prod_{j=1}^{n} p(x_j; \mu_j, \sigma_j^2)$$

$$p(x_1 = high\ temp) = 1/10$$

$$p(x_2 = high\ vibra) = 1/20$$

$$p(x_1, x_1) = p(x_1) * p(x_2) = \frac{1}{10} * \frac{1}{20} = \frac{1}{200}$$

3.选择参数ε

引入交叉验证数据集，并且在检验数据中加入一些带有标签的数据（异常/非异常），会很有用

The importance of real-number evaluation

When developing a learning algorithm (choosing features, etc.), making decisions is much easier if we have a way of evaluating our learning algorithm.

Assume we have some labeled data, of anomalous and non-anomalous examples. ($y = 0$ if normal, $y = 1$ if anomalous).

Training set: $x^{(1)}, x^{(2)}, \ldots, x^{(m)}$ (assume normal examples/not anomalous) ← $y=0$

Cross validation set: $\left(x_{cv}^{(1)}, y_{cv}^{(1)}\right), \ldots, \left(x_{cv}^{(m_{cv})}, y_{cv}^{(m_{cv})}\right)$

Test set: $\left(x_{test}^{(1)}, y_{test}^{(1)}\right), \ldots, \left(x_{test}^{(m_{test})}, y_{test}^{(m_{test})}\right)$

Include a few anomalous examples $y=1$

让我们用飞机发动机的例子来说明这一点。

Let's illustrate this with the aircraft engine example.

DeepLearning.AI Andrew Ng

使用交叉验证数据集的目的是确定合适的ε值，虽然这是无监督学习，但是引入带标签的数据对于训练算法十分有效

在CV数据集上确定了合适的ε，再用test set检验算法的准确度

还可以只用Training set与CV set，这种情况主要是异常案例很少时，没有足够数据创建一个与CV集完全不同的test set，但是无法评估算法在新数据上的工作性能，可能对ε与特征选择过拟合

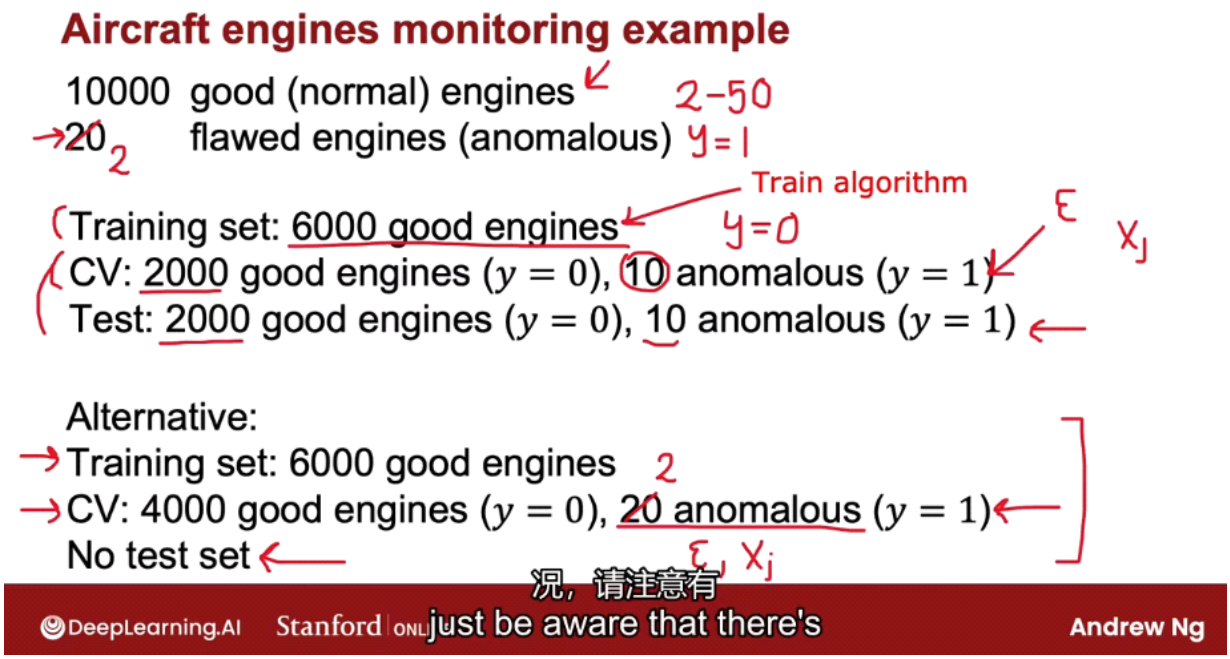

况，请注意有
just be aware that there's

屏幕剪辑的捕获时间: 2023/6/4 22:09

既然用了Labeled data，为何不用监督学习，而是用异常监测?

1.当“异常”数据的数量很小时，倾向于用异常监测，而当“异常”数据较多时，可以使用监督学习

2.如果“异常”的种类可能有许多，未来出现的异常情况很可能与现有的异常情况全都不相同，这种情况下Anomaly Detection会更合适，如金融诈骗；

如果认为未来会出现的“异常”情况与现有的情况很相似，就可以考虑采用监督学习，这种情况下还要有足够的案例让算法学习“异常”的特征，如垃圾邮件监测。

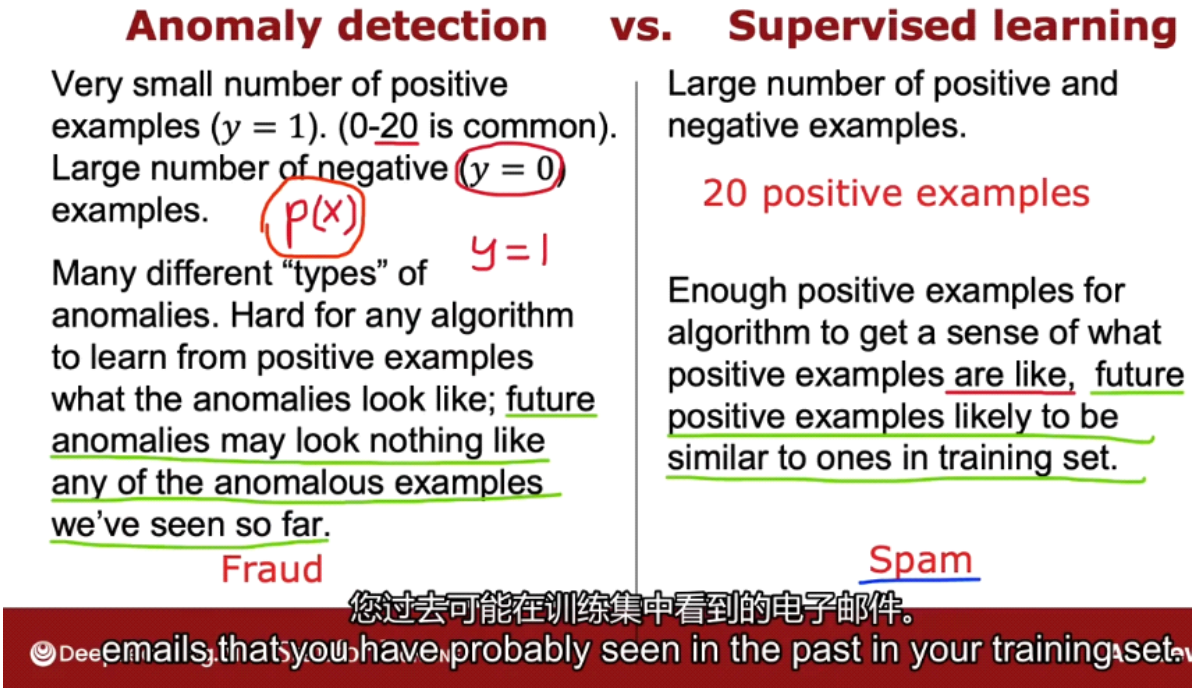

您过去可能在训练集中看到的电子邮件。
emails that you have probably seen in the past in your training set.

屏幕剪辑的捕获时间: 2023/6/6 15:49

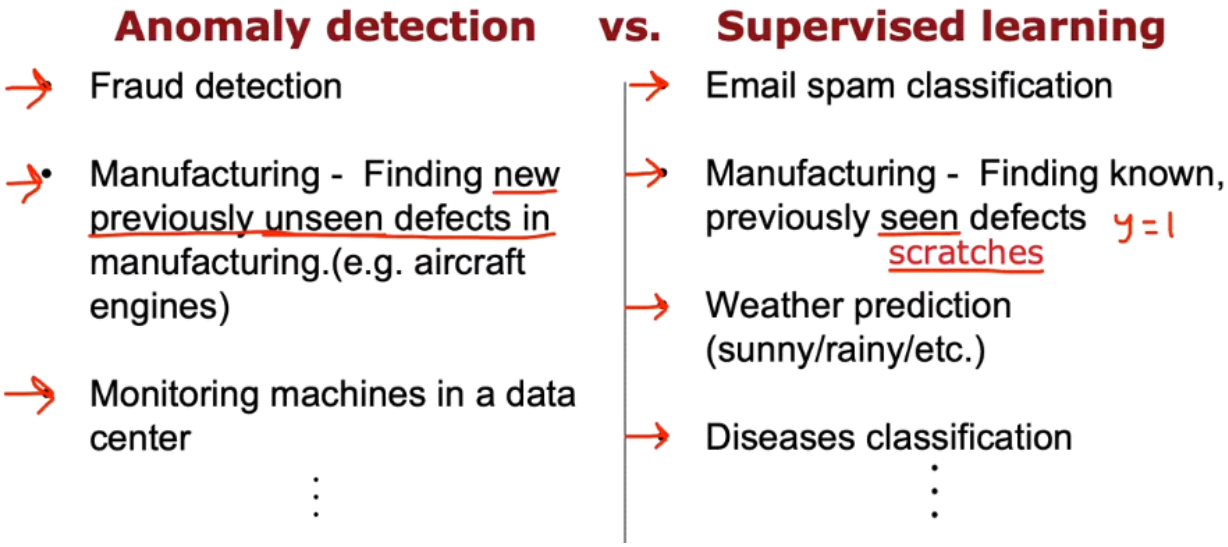

屏幕剪辑的捕获时间: 2023/6/11 9:31

总之，异常监测偏向于找出数据中与平常情况不同的个例，尤其是Training Set中未出现过的情况；而监督学习目的是**学会**如何分辨不同的异常情况，所以更多时候适用于检查Training Set中出现过的异常情况

4.如何选择特征

选择特征的重要性比监督学习更重要，尤其是需要符合高斯分布的特征，如果不符合高斯分布，可以通过一些变换使其近似于高斯分布

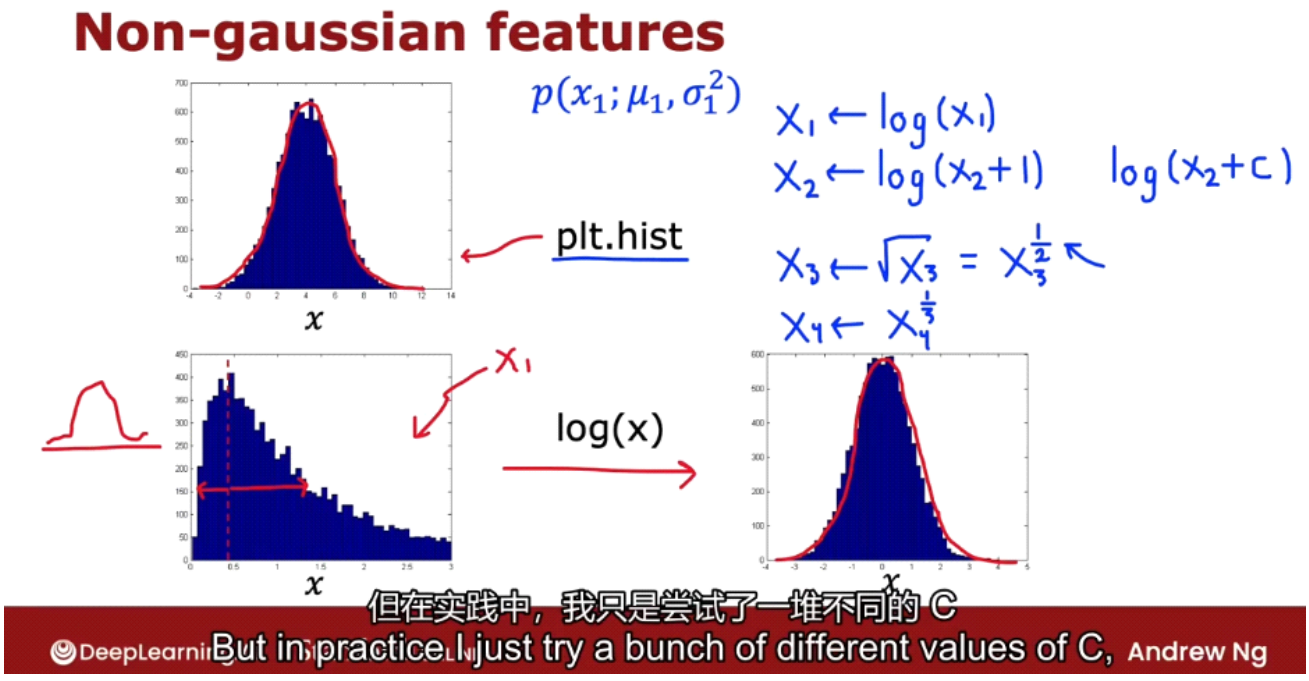

屏幕剪辑的捕获时间: 2023/6/11 9:47

5.误差分析

试想，如果**实际**有一些数据是**异常**的，但是将其放在训练集中来看，**异常的概率与正常的概率相近且都很大**，那么这可能说明需要一些其他的特征来区分异常与否，即通过观察这个异常的个例，思考是什么让我认为他是异常的，从而加入其他的特征改善算法

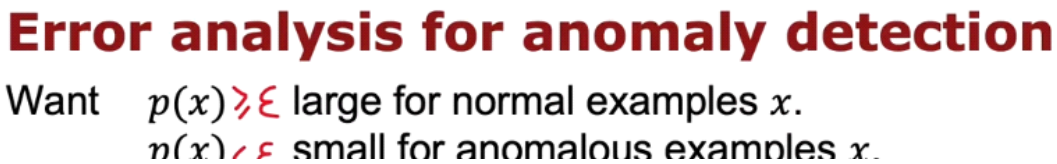

Error analysis for anomaly detection

Want $p(x) \geq \varepsilon$ large for normal examples x.
$p(x) < \varepsilon$ small for anomalous examples x.

Most common problem:
$p(x)$ is comparable (say, both large) for normal and anomalous examples

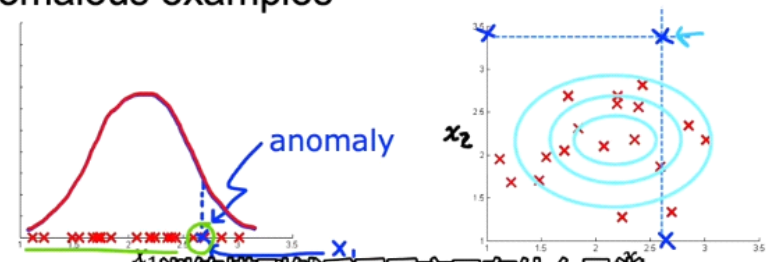

，训练模型然后看看交叉有什么异常
to train the model and then to see what anomalies in the cross
DeepLearning.AI Andrew Ng

屏幕剪辑的捕获时间: 2023/6/11 9:58

此外，有时在实际算法中，可能单独拿出监测指标中的一个来看是正常的，比如特征A很高，特征B很低，单独看都是正常的，但是这两种情况同时出现就是异常的，这时可以尝试组合原有的特征以产生新的特征

Monitoring computers in a data center

Choose features that might take on unusually large or small values in the event of an anomaly.

x_1 = memory use of computer
x_2 = number of disk accesses/sec
x_3 = CPU load ←
x_4 = network traffic ←

$$x_5 = \frac{\text{CPU load}}{\text{network traffic}} \qquad x_6 = \frac{(\text{CPU load})^2}{\text{network traffic}}$$

Deciding feature choice based on $p(x)$
– large for normal examples, and becomes small for anomaly in the cross validation set

对于正常示例仍然很大，但在您的交叉验证集中的异常中它变得很小。
it becomes small in the anomalies in your cross validation set.
DeepLearning.AI Andrew Ng

屏幕剪辑的捕获时间: 2023/6/11 10:03